Mineração e Análise de Sensibilidade de Métricas DORA em Repositórios Open-Source

Marcela Mendes Campos[1], Gabriel Assis de Souza[1], João Pedro Peres Barbosa[1]

Curso de Engenharia de Software – Pontifícia Universidade Católica de Minas Gerais (PUC Minas)
Belo Horizonte – MG – Brasil
{marcelacamposm2, dunkrells23, joaopedroperes06}@gmail.com

Abstract

DORA metrics are the industry benchmark for software delivery performance, but GitHub records neither production deployments nor production failures, so mining them requires proxies. We built a reproducible pipeline and mined 330 popular open-source repositories that use GitHub Actions over a 12-month window (2025-10-01 to 2026-09-30). Medians were 0.499 releases/week, 10.4 days of lead time (by release) and 4.7% CI-based change failure rate; 51.5% of the repositories fall in the Elite or High overall tier. Contributor count and project age are associated with longer lead times (Kruskal-Wallis with Holm correction, $\epsilon^2 = 0.211$ and 0.354), while stars are not associated with any metric. Both failure proxies correlate positively with deployment frequency ($\rho = +0.161$ for CI, $+0.497$ for corrective releases within 7 days), contrary to DORA. Between 21.5% and 25.8% of the repositories change overall tier depending on the pair of proxy definitions. Validation used three independent label sets; the corrective-release heuristic reached F1 = 0.625 against the automatic consensus and 0.437 against a 150-release subset of one label set.

Resumo

As métricas DORA são o padrão de mercado para medir o desempenho de entrega de software, mas o GitHub não registra implantações nem falhas em produção, de modo que sua mineração exige *proxies*. Construímos um pipeline reprodutível e minerâmos 330 repositórios open-source populares com GitHub Actions em uma janela de 12 meses (01/10/2025 a 30/09/2026). As medianas foram 0,499 releases/semana, 10,4 dias de *lead time* (por release) e 4,7% de taxa de falha pelo CI; 51,5% dos repositórios ficaram nas faixas gerais Elite ou High. Número de contribuidores e idade do projeto associam-se a *lead times* maiores (Kruskal-Wallis com correção de Holm, $\epsilon^2 = 0{,}211$ e $0{,}354$), enquanto estrelas não se associam a nenhuma métrica. Os dois proxies de falha correlacionam-se positivamente com a frequência de deploy ($\rho = +0{,}161$ para o CI e $+0{,}497$ para releases corretivas em até 7 dias), ao contrário do relatado pelo DORA. Entre 21,5% e 25,8% dos repositórios mudam de faixa geral conforme o par de definições de *proxy*. A validação usou três conjuntos de rótulos independentes; a heurística de release corretiva obteve F1 de 0,625 contra o consenso automático e 0,437 contra um subconjunto de 150 releases de um dos conjuntos.

1 Introdução

A mensuração do desempenho de entrega de software é central para a engenharia moderna. Formalizadas pelo DORA e pela obra *Accelerate* [1], quatro métricas resumem a capacidade operacional: *Deployment Frequency* e *Lead Time for Changes* (velocidade), *Change Failure Rate* (CFR) e *Failed Deployment Recovery Time* (estabilidade). O DORA sustenta que velocidade e estabilidade não são um *trade-off*.

O GitHub não registra implantações em produção nem falhas de serviço. Projetos de software livre publicam *releases*, executam *workflows* de CI e recebem *commits*, e é a partir disso que as métricas são inferidas por *proxies*: uma release publicada é o proxy de um deploy, e uma execução de CI que falhou é o proxy de uma falha. Uma biblioteca que publica uma release por mês não "implanta" nada em produção; quem o faz são seus usuários. Por isso, este trabalho calcula as métricas em 330 repositórios populares e também mede o quanto se pode confiar nelas: valida a heurística de falha contra rótulos manuais e quantifica quanto a classificação DORA muda quando a definição do proxy muda (RQ 07).

1.1 Questões de Pesquisa e Hipóteses

As hipóteses abaixo foram registradas no repositório do grupo antes da análise dos dados, e os veredictos estão na Seção 3.5.

- **RQ 01** (frequência de deploy): mediana inferior a 0,5 releases/semana, concentração em Medium e High e casos Elite raros.
- **RQ 02** (*lead time*): a variante (b), por commit, na faixa Medium; a variante (a), por release, bem maior que (b), com frequência na faixa Low e IQR mais largo.
- **RQ 03** (CFR): o CFR (a), de CI, entre 15% e 30%; o CFR (b), de entrega, abaixo de 15%.
- **RQ 04** (recuperação): concentração em High e Medium, Elite raro, Low minoritário e 5% a 15% de episódios censurados.
- **RQ 05** (velocidade $\times$ estabilidade): correlação fraca e negativa, ou próxima de zero, com o CFR (b), e fraca e positiva com o CFR (a), ressalvado um possível viés de acoplamento mecânico no CFR (b).
- **RQ 06** (fatores): mais contribuidores e mais estrelas levam a maior frequência de deploy e a recuperação mais heterogênea; repositórios mais antigos têm menor CFR (a); JavaScript/TypeScript e Python têm maior frequência que linguagens de sistemas; aplicações e CLIs têm maior cadência que bibliotecas.
- **RQ 07** (sensibilidade): alta sensibilidade, com 35% a 60% de migração, κ linear em $[0{,}30; 0{,}55]$ entre C1 e C2 e em $[0{,}45; 0{,}65]$ entre C1 e C3, C2 sistematicamente acima de C1 e C3 elevando a frequência dos projetos que só usam tags.

2 Metodologia

2.1 Pipeline e Funil de Amostragem

A coleta foi feita por scripts próprios (API REST e GraphQL, sem bibliotecas prontas de acesso ao GitHub), executáveis com um único comando e com cache SQLite em modo

WAL, retomada após interrupção, tratamento de *rate limit* por cabeçalhos com *backoff* exponencial, bissecção recursiva da janela quando uma consulta atinge o teto de 1.000 itens e clone Git *blobless* local para extrair tags e commits sem gastar cota. O dataset final foi regenerado em 22/10/2026 após três correções (janela com o último dia inteiro, tags de linhas de manutenção que o clone omitia, o que reduziu de 61 para 1 os repositórios sem *lead time*, e *runs* antes truncados em 1.000 por intervalo); os resultados referem-se a essa versão.

A janela de observação é 2025-10-01 a 2026-09-30, com os dois dias incluídos (365 dias, 52,14 semanas), considerando apenas o *default branch*. A Tabela 1 mostra o funil: 753 candidatos da Search API (`stars:>1000`, em ordem decrescente de estrelas) resultaram em 330 repositórios, com 25.943 releases e 3.329.182 *workflow runs* na janela.

Tabela 1: Funil de seleção dos repositórios.

Etapa	**Restam**	**Descartados**	**Motivo**
Candidatos avaliados (Search API)	753	–	avaliados até atingir a meta
Usa GitHub Actions	697	56	sem workflows ou erro de acesso
≥ 5 releases publicadas na janela	382	315	menos de 5 releases
≥ 50 runs de push no *default branch*	332	50	menos de 50 runs válidos
Clone Git local íntegro	330	2	falha irrecuperável no clone

2.2 Definições Operacionais e Classificação DORA

Deploy é uma release publicada (`draft = false`, `prerelease = false`) e a frequência é o número de releases dividido por 52,14 semanas. O *lead time* de uma release é a diferença entre sua data e `commit.author.date`, tomando o commit mais antigo nela incluído na variante (a), com mediana entre as releases do repositório, e a mediana de todos os commits de todas as releases na variante (b). Releases sem release anterior ficam fora do cálculo. O CFR (a) é $N_{\text{falha}}/(N_{\text{falha}} + N_{\text{sucesso}})$ sobre os *runs* do *default branch* disparados por `push`, tratando `failure`, `timed_out` e `startup_failure` como falha e ignorando execuções canceladas, puladas, neutras ou em andamento. No CFR (b), uma release falha se for seguida em até 7 dias por uma release corretiva, e as releases dos 7 últimos dias da janela ficam fora do denominador por censura. O tempo de recuperação é, para cada episódio de falha de um mesmo *workflow*, o intervalo entre `run_started_at` da primeira falha e `updated_at` do próximo sucesso, com mediana por repositório; episódios sem sucesso até o fim da janela são censurados. Um repositório sem nenhum episódio de falha foi classificado como Elite em recuperação, e um com todos os episódios censurados foi classificado como Low.

As faixas seguem a tabela fixa do guia da disciplina: frequência de deploy Elite $\geq$ 7/semana, High $\geq$ 1 e $<$ 7/semana, Medium $\geq$ 1/mês e $<$ 1/semana e Low $<$ 1/mês; *lead time* Elite $<$ 1 dia, High até 1 semana, Medium até 30 dias e Low acima disso; CFR Elite $\leq 15\%$, High $\leq 30\%$, Medium $\leq 45\%$ e Low acima disso; recuperação Elite $<$ 1 h, High $<$ 1 dia, Medium $<$ 1 semana e Low acima disso. A classificação geral é a mediana das quatro notas (Elite $= 4$ a Low $= 1$), arredondada para baixo; se uma métrica não tiver valor (um repositório sem *lead time*), a mediana é calculada sobre as três restantes. O CFR (b) não entra na nota geral. Para a análise de sensibilidade foram definidas três combinações: **C1** (referência: release, *lead time* (a), CFR (a)), **C2** (release e pré-release,

lead time (b), CFR (b)) e **C3** (tag Git, *lead time* (b), CFR (a)).

2.3 Validação Manual (Amostra-Ouro) e Proveniência dos Rótulos

Foram sorteados 60 repositórios da amostra final com semente fixa (`random_state=42`) e 5 releases de cada (300 releases). Para cada repositório rotulou-se o tipo do projeto (biblioteca/framework, aplicação/serviço, ferramenta CLI ou outro) e se as releases representam entregas reais; para cada release, se é corretiva. Cada um dos três conjuntos de rótulos (identificados como Gabriel, João e Marcela) foi produzido de forma independente, sem acesso à saída da heurística nem aos demais conjuntos; o conjunto de Gabriel tem independência parcial, pois o rotulador conhecia a regra da heurística v1. O conjunto de Marcela foi produzido em dois lotes de 150 releases (30 repositórios cada). A reunião de consenso foi dispensada por falta de tempo; o consenso é a maioria simples automática (empate 1-1-1 vira "outro" ou "incerto"; em tipo do projeto, 48 repositórios foram unânimes, 11 por maioria e 1 empate).

O kappa de Fleiss [4], interpretado pela escala de Landis e Koch [3], foi $\kappa = 0{,}787$ para tipo do projeto (80,0% de unanimidade, substancial), $\kappa = 0{,}492$ para entrega real (96,7% de unanimidade) e $\kappa = 0{,}625$ para release corretiva (72,3% de unanimidade, substancial). O kappa de entrega real não é informativo: 176 dos 180 votos são "sim" (97,8%), o que eleva a concordância esperada ao acaso a cerca de 0,96 e derruba o kappa com poucas divergências. Há heterogeneidade dentro do conjunto de Marcela: o kappa de release corretiva é de 0,368 (razoável) no primeiro lote e de 0,858 (quase perfeito) no segundo, e o kappa de Cohen entre cada um dos outros dois conjuntos e o primeiro lote é de 0,11 a 0,13 (leve) em release corretiva e de 0,51 a 0,59 (moderado) em tipo do projeto.

A heurística v1 de release corretiva marca uma release quando só o número de *patch* SemVer sobe em relação à release anterior e algum commit entre elas cita `fix`, `hotfix` ou `revert`. Contra o consenso automático (298 releases avaliadas; 2 eram primeiras releases) ela obteve precisão de 61,4%, *recall* de 63,8% e F1 de 0,625 (IC95% por *bootstrap* por repositório: 0,519 a 0,717), próximo do F1 de 0,598 de marcar todas as releases como corretivas; contra o primeiro lote de 150 releases do conjunto de Marcela, o F1 foi de 0,437, abaixo do piso de 0,574 do classificador trivial. A versão `v1_full_message`, que lê a mensagem completa dos commits, obteve F1 de 0,621 e 0,443, na mesma ordem. Nenhuma versão atingiu o F1 de 0,70 exigido em nenhuma das cinco referências testadas (máximo de 0,667), e a v1 foi mantida no cálculo do CFR (b). Dos 51 falsos positivos, 50 ocorrem em releases cujo *patch* sobe: em projetos de cadência alta esses *patches* reúnem funcionalidade e correção (mediana de 30 commits e 10 `fix`, contra 11 e 3 nos verdadeiros positivos). Dos 46 falsos negativos, 13 são releases de manutenção de uma linha antiga (a versão "diminui") e 14 são releases *minor* com correções.

O tipo do projeto usado na RQ 06 foi rotulado nos 330 repositórios por três agentes de IA, harmonizados por uma rubrica única. A concordância desses rótulos com os 60 rótulos de tipo do conjunto de Marcela foi de 66,7% (κ de Cohen $= 0{,}44$, moderado).

2.4 Análise Estatística

Reportam-se mediana e IQR; a RQ 05 usa o ρ de Spearman. Na RQ 06, estrelas, contribuidores e idade foram divididos em quartis, a linguagem em seis linguagens e "Outras" e o

tipo em quatro categorias. Aplicou-se o teste de Kruskal-Wallis [6] a cada combinação de 5 fatores e 5 métricas (frequência de deploy, *lead time* (b), CFR (a), CFR (b) e recuperação), 25 testes ao todo, com correção de Holm [7] e tamanho de efeito $\epsilon^2 = H/(n-1)$ [8], interpretado como desprezível ($< 0{,}01$), pequeno ($< 0{,}06$), médio ($< 0{,}14$) ou grande. Entre os quartis extremos usou-se o delta de Cliff, interpretado por Romano et al. [9]. Na RQ 07 calcularam-se a proporção de repositórios que mudam de faixa e o kappa de Cohen ponderado linear [5] para cada par entre C1, C2 e C3.

3 Resultados e Discussão

3.1 RQ 01 a RQ 04: as Quatro Chaves DORA

A Tabela 2 traz as distribuições, assimétricas e de cauda longa.

Tabela 2: Mediana, quartis e distribuição por faixa DORA ($n = 330$ salvo indicação).

Métrica	n	**Med.**	**Q1**	**Q3**	**IQR**	**Elite**	**High**	**Med.**	**Low**
Freq. deploy (rel./sem.)	330	0,499	0,249	1,208	0,959	2,7	26,1	49,4	21,8
Lead time (a) (h)	329	249,98	77,38	941,49	864,11	14,9	25,2	30,1	29,8
Lead time (b) (h)	329	289,66	82,89	1319,83	1236,93	10,9	27,1	30,1	31,9
CFR (a), CI (prop.)	330	0,047	0,024	0,111	0,087	83,3	10,9	3,3	2,4
CFR (b), entrega (prop.)	328	0,186	0,038	0,408	0,369	45,7	20,1	14,9	19,2
Recuperação (h)	312	2,61	1,05	6,62	5,58	27,3	61,2	9,7	1,8
Classificação geral (C1)	330		–			7,0	44,5	44,2	4,2

Faixas em % dos repositórios com valor; em recuperação, sobre os 330 (14 sem falhas: Elite; 4 só com censurados: Low).

Frequência de deploy (RQ 01). A mediana é de 0,499 releases por semana (cerca de uma a cada duas semanas); 49,4% dos repositórios estão em Medium e 26,1% em High, e só 9 (2,7%) são Elite. Os 21,8% em Low (menos de uma release por mês) ocorrem apesar do piso de 5 releases.

***Lead time* (RQ 02).** As medianas são de 10,4 dias (a) e 12,1 dias (b), e cerca de 30% dos repositórios estão em Low em ambas. Em 137 dos 329 repositórios o *lead time* (b) supera o (a). Isso não é erro: dentro de uma release, (b) nunca excede (a), mas entre releases (a) é a mediana por release, em que cada uma pesa 1, enquanto (b) é a mediana de todos os commits, em que cada release pesa pelo seu número de commits. Uma release *major* grande e demorada, seguida de *patches* pequenos, domina (b) e quase não afeta (a): em `charmbracelet/bubbletea`, a `v2.0.0` concentra 759 dos 817 commits (mediana de 377 dias), e o *lead time* é de 6,1 dias na variante (a) e 335,9 na (b). O cenário da hipótese, em que um commit antigo e esquecido eleva (a), afeta uma única release, e a mediana entre releases o dilui.

CFR (RQ 03). O CFR (a) é baixo (mediana de 4,7%; 83,3% dos repositórios em Elite), pois falhas de *pipeline* num *default branch* costumam ser raras e corrigidas rápido. O CFR (b) é quase quatro vezes maior (mediana de 18,6%); no total, 7.947 das 24.846 releases avaliadas (32,0%) foram seguidas por uma release classificada como corretiva em até 7 dias, e 1.097 releases dos últimos 7 dias foram censuradas. Dois repositórios não têm release avaliável e ficaram sem CFR (b). Dado o desempenho da heurística (Seção 2.3), o CFR (b) é um indicador ruidoso, não uma taxa de falha em produção.

Recuperação (RQ 04). A mediana é de 2,61 horas e 61,2% dos repositórios estão

em High. A faixa Elite não é rara (27,3%): dos 90 repositórios nela, 14 nunca tiveram um episódio de falha, mas 76 dos 312 com recuperação medida (24,4%) têm mediana inferior a 1 hora. Isso é coerente com o que o proxy mede: o tempo até o próximo *run* verde do mesmo *workflow* inclui reexecuções e correções triviais, e não a restauração de um serviço. Em 157 repositórios (47,6%) há episódios censurados (média de 3,5% por repositório) e em 4 todos foram censurados (Low).

Classificação geral. Elite e High somam 51,5% e Medium 44,2%; só 4,2% são Low, mas a classificação é sensível às definições (Seção 3.4).

3.2 RQ 05: Frequência de Deploy × Taxa de Falha

O ρ de Spearman é de $+0{,}161$ ($p = 0{,}0033$, $n = 330$) com o CFR (a), correlação fraca e positiva, e de $+0{,}497$ ($p = 7{,}6 \times 10^{-22}$, $n = 328$) com o CFR (b), correlação moderada e positiva. As duas correlações são positivas: em ambos os proxies, quem publica mais também falha mais, o oposto da tese do DORA de que as equipes de melhor desempenho vão bem nas duas dimensões. Para o CFR (a), a explicação prevista é que repositórios mais ativos executam mais e mais variados *workflows*, com mais ocasiões de falha de *pipeline* sem que a entrega piore (não testada). Correlação não implica causalidade.

Para o CFR (b), a hipótese era de um acoplamento mecânico: quem publica muito tem releases separadas por menos de 7 dias com mais frequência, o que infla o proxy. Os dados apoiam só em parte essa explicação. A correlação persiste dentro de cada quartil de idade (ρ entre 0,32 e 0,54) e na correlação parcial controlando a idade ($\rho = 0{,}41$), de modo que a idade não a explica. Porém, entre os 94 repositórios com pelo menos uma release por semana, onde o acoplamento mecânico deveria ser maior, ρ é de apenas $+0{,}12$ ($p = 0{,}27$), enquanto entre os 234 com menos de uma por semana é de $+0{,}47$ ($p < 10^{-13}$). A relação, portanto, não vem dos repositórios de cadência mais alta. Também sob C2 (releases e pré-releases) e C3 (tags) a correlação positiva se mantém ($\rho = +0{,}39$ entre frequência e CFR (b) em C2 e $+0{,}19$ entre frequência e CFR (a) em C3). Não testamos, por exemplo, outras janelas de 7 dias, e o mecanismo permanece uma conjectura.

3.3 RQ 06: Fatores Associados ao Desempenho

Dos 25 testes, 7 permanecem significativos após a correção de Holm (Tabela 3); os outros 18 têm $p_{\text{Holm}} \geq 0{,}107$ e $\epsilon^2 \leq 0{,}047$. Estrelas não se associam a nenhuma das cinco métricas ($p_{\text{Holm}} = 1{,}000$; $\epsilon^2 \leq 0{,}017$), embora a frequência mediana suba de 0,36 para 0,73 do primeiro ao último quartil (sem significância).

Os quartis de contribuidores vão de 8–209 a 989–9.915, e os de idade vão de projetos criados após março de 2024 a projetos criados até 2015. Projetos com mais contribuidores e mais antigos têm *lead time* maior (delta de Cliff entre Q1 e Q4 grande: $\delta = -0{,}69$ e $-0{,}85$); os mais antigos têm também frequência de deploy menor ($\delta = +0{,}48$ a favor dos mais novos) e CFR (b) menor ($\delta = +0{,}62$). Esses dois fatores estão fortemente correlacionados entre si ($\rho = +0{,}58$), e as análises são univariadas, de modo que não se pode separar o efeito de cada um. A queda do CFR (b) com a idade pode refletir o mesmo viés do proxy, já que projetos antigos publicam menos.

Tabela 3: Testes de Kruskal-Wallis significativos após correção de Holm (25 testes).

Fator × métrica	H	p**-Holm**	ϵ^2	**Medianas por grupo**
Contribuidores × LT (b)	69,30	$1{,}45 \times 10^{-13}$	0,211 (grande)	Q1 129 h; Q2 179; Q3 323; Q4 1845
Idade × Freq. deploy	32,81	$7{,}79 \times 10^{-6}$	0,100 (médio)	Q1 0,86; Q2 0,60; Q3 0,36; Q4 0,35
Idade × LT (b)	116,04	$1{,}37 \times 10^{-23}$	0,354 (grande)	Q1 70 h; Q2 235; Q3 520; Q4 1747
Idade × CFR (b)	60,18	$1{,}24 \times 10^{-11}$	0,184 (grande)	Q1 0,33; Q2 0,27; Q3 0,14; Q4 0,04
Linguagem × Freq. deploy	20,90	$3{,}63 \times 10^{-2}$	0,064 (médio)	TS 0,83; Py 0,66; Go 0,44; Rust 0,43; JS 0,37; C++ 0,23
Linguagem × LT (b)	32,10	$3{,}29 \times 10^{-4}$	0,098 (médio)	Py 119 h; TS 266; Rust 286; JS 433; Go 463; C++ 1180
Tipo × LT (b)	23,26	$7{,}12 \times 10^{-4}$	0,071 (médio)	outro 74 h; CLI 148; app 295; lib 606

$n = 329$ ou 330. Q1 a Q4: do menor para o maior número de contribuidores e do mais novo para o mais antigo. $k = 4$, exceto linguagem ($k = 7$).

3.4 RQ 07: Sensibilidade às Definições Operacionais

A Tabela 4 mostra as transições entre combinações. As distribuições gerais variam entre combinações: Elite/High/Medium/Low são 23/147/146/14 em C1, 9/139/164/18 em C2 e 26/177/116/11 em C3.

Tabela 4: Mudança de faixa DORA geral entre combinações de proxies ($n = 330$).

Par	**Mudaram**	**%**	**Subiram**	**Desceram**	κ **linear**
C1 × C2	84	25,5	25	59	0,603 (substancial)
C1 × C3	71	21,5	54	17	0,687 (substancial)
C2 × C3	85	25,8	81	4	0,622 (substancial)

"Subiram" e "desceram": do primeiro para o segundo elemento do par.

Cerca de 75% dos repositórios mantêm a faixa geral entre dois proxies quaisquer. A passagem de C1 para C2 desce mais repositórios (59) do que sobe (25), porque o CFR (b) é maior que o CFR (a) e o *lead time* (b) é maior que o (a). A passagem para C3 sobe 54: 237 repositórios (72%) têm mais tags que releases na janela, e neles a frequência mediana vai de 0,61 para 1,05 por semana. A concordância medida pelo kappa é substancial (0,60 a 0,69), ou seja, a sensibilidade é moderada, mas não desprezível: cerca de um repositório em cada quatro troca de faixa conforme a definição, o que é relevante para quem usar a faixa como indicador gerencial. Quanto à robustez, a RQ 05 se mantém sob C2 e C3; as RQs 01 a 04 mudam de valor (a mediana de frequência vai de 0,499 em C1 a 0,633 em C2 e 0,825 em C3); a RQ 06 só foi testada sob C1.

3.5 Hipóteses × Resultados

A Tabela 5 resume o confronto. Das 15 previsões, 3 foram confirmadas, 3 parcialmente, 4 não se sustentaram (sem associação significativa) e 5 foram refutadas (resultado contrário).

O que mais surpreendeu foi a inversão entre os proxies: esperávamos o CFR (b) abaixo do (a) e o *lead time* (a) acima do (b), e ocorreu o contrário nos dois casos; nos casos conferidos, o que domina é uma release grande, que pesa na variante (b), e não um commit esquecido. Também surpreendeu que a idade não se associe ao CFR (a) e que tipo do projeto e popularidade praticamente não se associem à cadência. Para quem mede DORA

Tabela 5: Hipóteses (formuladas antes dos dados) e resultados.

RQ	Hipótese	Resultado	Veredito
01	Mediana $< 0{,}5$; Medium/High; Elite raro	0,499; 75,5% em Medium/High; Elite 2,7%; 21,8% em Low não previstos	Confirmada
02	(b) Medium; (a) $\gg$ (b), Low, IQR maior	(b) = 12,1 d (Medium); (a) = 10,4 d, abaixo de (b); IQR de (a) menor; Low em 29,8% (a)	Parcial
03	CFR (a) 15–30%; CFR (b) $< 15\%$	(a) = 4,7% (Elite); (b) = 18,6% (High); ordem invertida	Refutada
04	High/Medium; Elite raro; censura 5–15%	High 61,2%, Medium 9,7%, Low 1,8%; Elite 27,3%; censura média de 3,5%	Parcial
05.1	CFR (b): ρ fraco negativo ou ≈ 0	$\rho = +0{,}497$	Refutada
05.2	CFR (a): ρ fraco positivo	$\rho = +0{,}161$	Confirmada
06.1	Contribuidores: mais deploys, recuperação heterogênea	Deploys: $\epsilon^2 = 0{,}011$ (n.s.); IQR da recuperação cai de 10,4 h (Q1) para 2,9 h (Q4)	Não sustentada
06.2	Estrelas: idem	Sem associação ($p_{\text{Holm}} = 1$); IQR sem padrão	Não sustentada
06.3	Idade maior: CFR (a) menor	Mediana de 0,060 a 0,038, $p_{\text{Holm}} = 0{,}77$	Não sustentada
06.4	JS/TS e Python com maior frequência	TS e Python lideram; JS (0,37) fica abaixo de Go e Rust	Parcial
06.5	Apps/CLI mais cadência que bibliotecas	0,52 e 0,54 contra 0,46; $\epsilon^2 = 0{,}002$ (n.s.)	Não sustentada
07.1	35–60% de migração	21,5–25,8%	Refutada
07.2	$\kappa \in [0{,}30; 0{,}55]$ (C1,C2) e $[0{,}45; 0{,}65]$ (C1,C3)	0,603 e 0,687, acima das faixas	Refutada
07.3	C2 sistematicamente acima de C1	59 descem, 25 sobem	Refutada
07.4	C3 eleva frequência (só tags)	237 repositórios; mediana de 0,61 a 1,05; 54 sobem	Confirmada

em código aberto, a conclusão sobre velocidade e estabilidade depende do proxy, e uma parte relevante da amostra muda de faixa conforme a definição.

4 Ameaças à Validade

As ameaças seguem as quatro categorias de Wohlin et al. [2] e se apoiam nos resultados da validação manual e da análise de sensibilidade. *De construto.* Release não é deploy: o kappa de entrega real foi 0,492, mas é inflado pela prevalência de "sim" (97,8%) e não informa; bibliotecas não se implantam em produção. Falha de CI não é falha em produção, e o tempo de recuperação mede a reexecução de um *workflow*, não um incidente. A heurística de release corretiva (F1 de 0,625 contra o consenso e 0,437 contra o primeiro lote do conjunto de Marcela) torna o CFR (b) ruidoso e sujeito ao viés de cadência da RQ 05. `commit.author.date` é distorcida por *rebases* e *squash merges*. A sensibilidade da RQ 07 (21,5% a 25,8%) mostra que a escolha do proxy muda o resultado.

Interna. A concordância dos rótulos da amostra-ouro varia entre lotes (κ de 0,37 a 0,86 em release corretiva); o consenso é automático, sem reunião; e o conjunto de Gabriel tem independência parcial. Como o kappa de Cohen entre conjuntos e o primeiro lote do

conjunto de Marcela é leve em release corretiva ($\kappa = 0{,}11$ a $0{,}13$), o F1 contra o consenso provavelmente superestima o desempenho da heurística. O tipo do projeto dos 330 repositórios foi rotulado por agentes, com concordância moderada com os rótulos de tipo do conjunto de Marcela ($\kappa = 0{,}44$, $n = 60$). Idade e contribuidores são correlacionados ($\rho = 0{,}58$) e os testes são univariados, e a idade confunde a RQ 06.

Externa. A amostra tem os 330 repositórios mais populares com GitHub Actions, com no mínimo 38.855 estrelas, o que restringe a variação dessa variável e limita a conclusão de que estrelas não importam; exigir pelo menos 5 releases e 50 *runs* favorece projetos ativos; e a composição é dominada por TypeScript (93) e Python (76). Os resultados não se estendem a projetos privados nem a outros sistemas de CI.

De conclusão. Os testes são não paramétricos, com correção de Holm para 25 comparações e tamanho de efeito, mas as releases de um mesmo repositório não são independentes; o IC95% do F1 (0,52 a 0,72) é largo, com 60 repositórios; os grupos de linguagem são desiguais ("Outras" é heterogêneo); e quartis e limiares de ϵ^2 são convenções.

5 Replicação Cruzada e Reprodutibilidade

O pipeline foi preparado para ser executado por outro grupo apenas com o README: um comando (`python -m pipeline -config config.yaml`), token em variável de ambiente, cache com retomada, funil gerado automaticamente e dicionário de dados das 44 colunas do CSV final. Os testes das funções de métricas rodam no GitHub Actions do repositório e cobrem 98% do módulo de métricas em medição local (meta: 80%). O repositório não contém, na data desta versão, o relato da execução do pipeline por outro grupo (30 repositórios, comparação com o CSV original e Issues abertas), de modo que o presente artigo não declara resultado de replicação.

6 Conclusão

Em 330 repositórios open-source populares, o desempenho DORA minerado fica predominantemente nas faixas Medium (44,2%) e High (44,5%), com 7,0% em Elite. Mais contribuidores e maior idade associam-se a *lead times* muito maiores, enquanto estrelas não se associam a nada. Velocidade e estabilidade correlacionam-se positivamente (mais releases, mais falhas), contra a expectativa do DORA, e esse resultado depende do proxy. A classificação muda para 21,5% a 25,8% dos repositórios conforme a definição, e a validação mostrou que a heurística de release corretiva não atingiu o F1 de 0,70 e que a concordância entre os rotuladores é heterogênea. Como trabalhos futuros, sugerem-se uma versão refinada da heurística (por exemplo, restrita à mesma linha de versão), rotulação humana de mais releases, análise multivariada dos fatores e outras janelas para o CFR (b).

Repositório: https://github.com/jaoppb/laboratorio-experimentacao-de-software
GitHub Projects: https://github.com/users/jaoppb/projects/3/views/1

Referências

[1] Nicole Forsgren, Jez Humble, and Gene Kim. *Accelerate: The Science of Lean Software and DevOps: Building and Scaling High Performing Technology Organizations*. IT Revolution, 2018.

[2] Claes Wohlin, Per Runeson, Martin Höst, Magnus C. Ohlsson, Björn Regnell, and Anders Wesslén. *Experimentation in Software Engineering*. Springer, 2012.

[3] J. Richard Landis and Gary G. Koch. The measurement of observer agreement for categorical data. *Biometrics*, 33(1):159–174, 1977.

[4] Joseph L. Fleiss. Measuring nominal scale agreement among many raters. *Psychological Bulletin*, 76(5):378–382, 1971.

[5] Jacob Cohen. Weighted kappa: Nominal scale agreement provision for scaled disagreement or partial credit. *Psychological Bulletin*, 70(4):213–220, 1968.

[6] William H. Kruskal and W. Allen Wallis. Use of ranks in one-criterion variance analysis. *Journal of the American Statistical Association*, 47(260):583–621, 1952.

[7] Sture Holm. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2):65–70, 1979.

[8] Maciej Tomczak and Ewa Tomczak. The need to report effect size estimates revisited: an overview of some recommended measures of effect size. *Trends in Sport Sciences*, 21(1):19–25, 2014.

[9] Jeanine Romano, Jeffrey D. Kromrey, Jesse Coraggio, and Jeff Skowronek. Appropriate statistics for ordinal level data: Should we really be using t-test and Cohen's d for evaluating group differences on the NSSE and other surveys? In *Annual Meeting of the Florida Association of Institutional Research*, 2006.